

Raport partial Moodle - Regresie salary

Acest raport acopera doar partea de regresie a temei: predictia coloanei salary.

Clasificarea pentru vacation va fi adaugata separat, dupa finalizarea acestei parti.

Cerinte PDF acoperite

Am verificat cerintele din PDF si partea de regresie acopera:

- EDA general: tipuri de attribute, valori lipsa, plaje de valori, outliers, distributii;
- analiza corelatiilor numerice si relatia feature-urilor cu salary;
- preprocessing justificat: imputare, tratare outliers, encoding, standardizare unde are sens;
- baseline cu LinearRegression;
- experimente de regularizare cu Ridge si Lasso;
- modele neliniare si boosting: arbori, RandomForest, ExtraTrees, XGBoost, LightGBM, CatBoost;
- K-Fold Cross-Validation pe train + test local;
- tabel comparativ cu metrici MAE/MSE/RMSE/R2;
- grafice de eroare train vs test;
- jurnalizarea pasilor spre cea mai buna solutie.

Date si target

Seturile folosite:

- CC_education_economy_train.csv: 64.000 randuri, cu salary si vacation;
- CC_education_economy_test.csv: 16.000 randuri locale, cu salary si vacation;
- CC_private_test.csv: 16.000 randuri private Kaggle, fara salary.

Pentru regresie, targetul este salary. Coloanele excluse din regresie:

- salary: targetul;
- vacation: targetul taskului de clasificare, risc de leakage;
- total_days_worked: aproape redundant cu experience_years.

Preprocessing

Pentru modelele liniare:

- numerice: imputare cu mediana + StandardScaler;
- categorice: imputare cu Missing + OneHotEncoder;
- motiv: modelele liniare sunt sensibile la scara variabilelor.

Pentru arbori si boosting sklearn/XGBoost/LightGBM:

- numerice: imputare cu mediana;
- categorice: imputare cu Missing + OneHotEncoder sau Target Encoding;
- fara standardizare, deoarece arborii nu au nevoie de scale comparabile.

Pentru CatBoost:

- am testat si varianta nativa cu categorice text;
- varianta cea mai buna local a folosit K-Fold Target Encoding + log1p(salary).

Feature engineering important:

- remote_work_missing;
- mapari ordinale pentru education_level, company_size, skill_bracket;
- skills_per_year, experience_x_skills, certifications_per_year;
- interactiuni de drift: edu_company, job_company, loc_company, edu_job.

Fir experimental

Etapă	Motiv	Rezultat / decizie
LinearRegression	baseline minim cerut de PDF	stabileste reperul initial
Ridge si Lasso	cerinta de regularizare	arata efectul penalizarii coeficientilor
Arbori si ensemble-uri	captam neliniaritati	boosting-ul si CatBoost devin mai bune
CatBoost + Target Encoding	categorice multe si importante	CV MSE aproximativ 27.56M
CatBoost + log target	target salary asimetric	CV MSE aproximativ 27.52M
Optuna CatBoost	tuning controlat al hiperparametrilor	CV MSE aproximativ 27.36M
Adversarial validation	testul privat difera de local	AUC adversarial mare, drift confirmat
Public-guided ensemble	combinam familii pe baza scorurilor publice	Kaggle 273.718M
Pseudo-labeling	modelul vede distributia privata	Kaggle 271.904M
LightGBM-heavy blend	feedback Kaggle arata ca LGBM corecteaza mai bine privatul	Kaggle 271.404M

Model final de regresie

Varianta finala confirmata pentru regresie este:

- submission_regression_final.csv

Ea este obtinuta din:

- 25% CatBoost pseudo-label model;
- 75% LightGBM pseudo-label model.

Scor Kaggle cunoscut pentru aceasta varianta:

- MSE: 271,404,123.79.

Interpretare

Local, CatBoost parea mai bun decat LightGBM. Totusi, adversarial validation a aratat ca testul privat are distributie diferita de train/test local. Din acest motiv, validarea locala simpla nu a fost suficienta pentru alegerea finala.

Pseudo-labeling-ul a ajutat pentru ca modelul a fost expus la distributia privata prin etichete slabe, iar LightGBM a corectat o parte din bias-ul CatBoost pe acea distributie. Blend-ul final nu este doar o medie intamplatoare: a fost ales dupa o secventa de rezultate locale si feedback Kaggle.

Fisiere relevante pentru predare

- main.ipynb: implementarea EDA + regresie + notebook de lucru;
- README.md: jurnalul complet al experimentelor;
- REGRESIE_RAPORT_MOODLE.pdf: acest raport exportat in PDF;
- submission_regression_final.csv: submission final pentru regresie;
- pruned_submission_csv_manifest.json: lista fisierelor de submission pastrate/sterse.